What is HADOOP & SPARK

In this presentation, I will explain Hadoop&Spark and how to use it.

Jeon Dabin

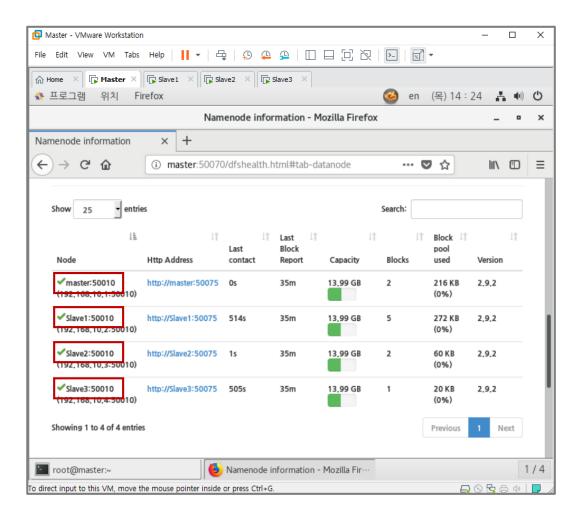
GitHub주소: https://github.com/DabinJeon/HADOOP

〈목차〉

- About Hadoop
- Hadoop Setup
- Hadoop-Mapreduce
- Hadoop-Java
- About Hive
- Hive Setup
- Hive-HiveQL
- About Spark
- Spark Setup
- Spark-Scala
- Spark-Python

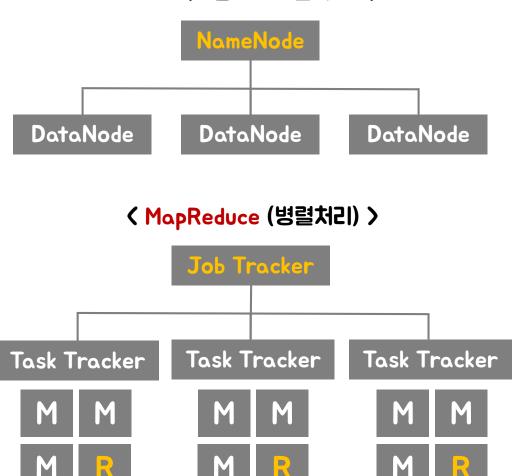
" Hadoop & Spark "

About Hadoop



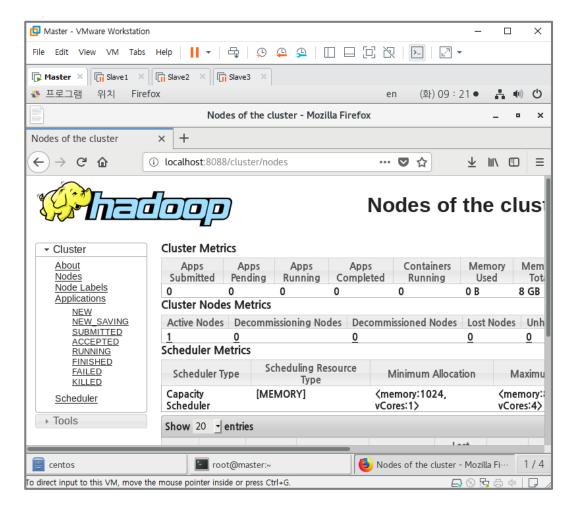
http://localhost:50070 -> NameNode, DateNode 확인

〈 HDFS (하둡분산파일시스템) 〉



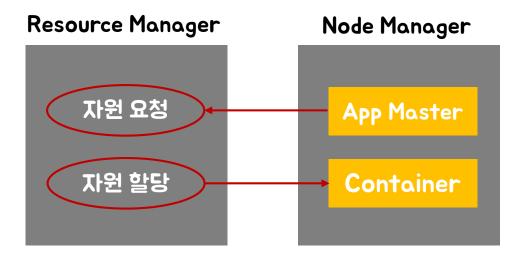
(각 TaskTracker마다 맵,리듀스 슬롯을 구분하여 작업을 처리)

About Hadoop



http://localhost:8088 -> YARN에 대한 인터페이스

〈 YARN (클러스터자원관리시스템) 〉

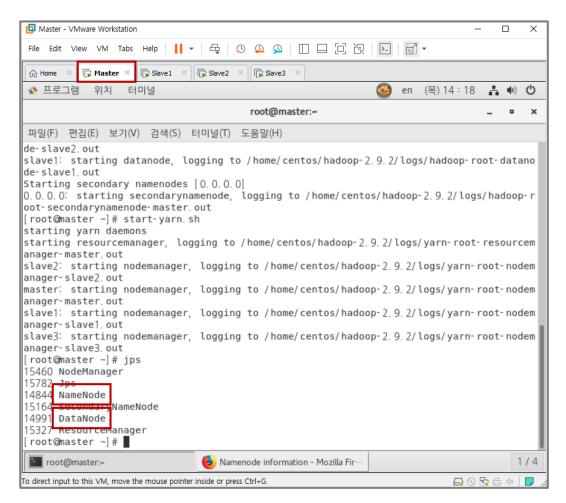


〈클러스터(자원) 관리〉

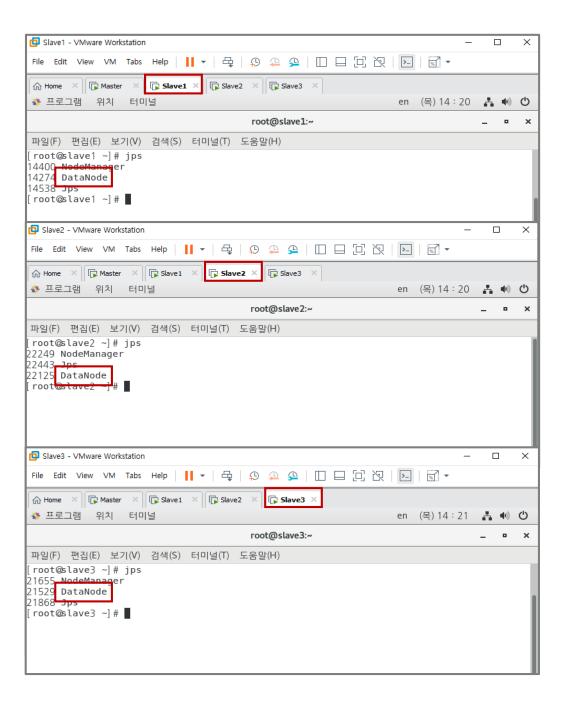
- 〈작업 관리〉
- Resource Manager
- Node Manager

- **Application Master**
- Container
- 1. 작업이 생기면 App Master가 생성됨
- 2. App Master는 Resource Manager에게 지원을 요청
- 3. 실제 작업을 담당하는 Container를 할당 받아서 작업처리
- 4 작업이 완료되면 Container종료

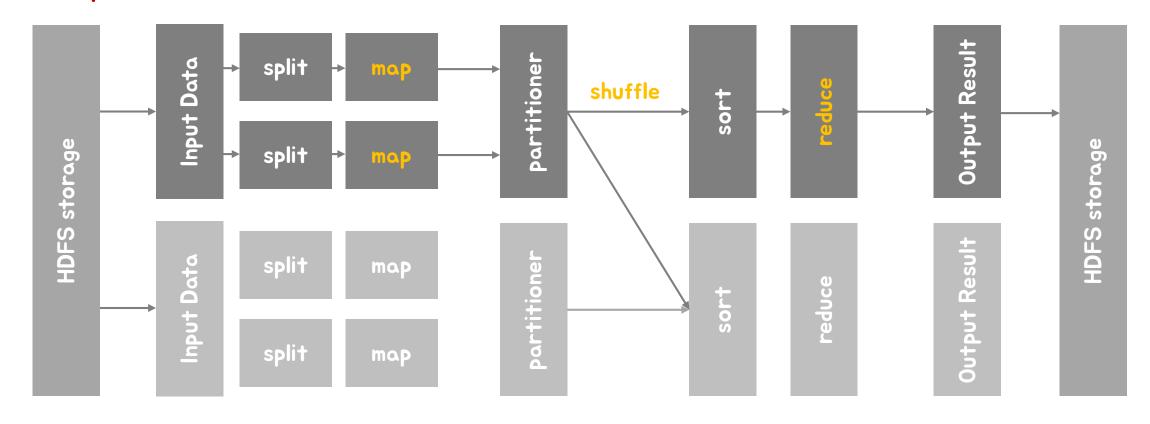
Hadoop Setup



- NameNode 17H: Master
- DataNode 47H: Master, Slave1, Slave2, Slave3



〈 MapReduce 처리단계 〉



Map : 입력을 분할하여 귀별로 데이터를 처리

• Combiner : 맵의 결과를 정리 (설정에 따라 없을 수도 있음)

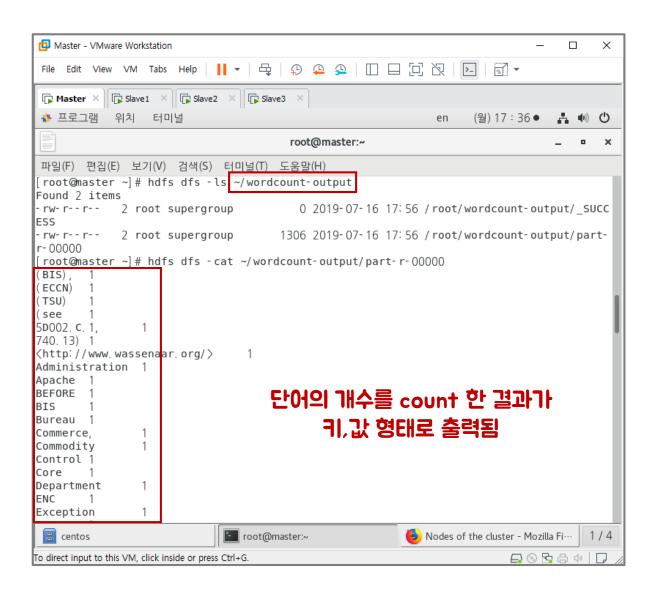
• Partitioner : 키값을 해쉬 처리하여 어떤 리듀서로 넘길지 결정

• Shuffle : 각 리듀서로 데이터 이동

• Sort : 리듀서로 전달된 데이터를 귀값 기준으로 정렬

• Reduce : 리듀서로 전달된 데이터를 처리하고 결과를 저장

〈 MapReduce 간단 동작 테스트 〉



* master에서 실행 *

@ 맵리듀스 job을 실행을 위해, HDFS 디렉토리 생성

hdfs dfs -mkdir /user/root
hdfs dfs -mkdir /user/root/conf

@ 테스트 파일을 HDFS에 업로드

hdfs dfs -mkdir /input hdfs dfs -copyFromLocal /home/centos/hadoop-2.9.2/README.txt /input hdfs dfs -ls /input

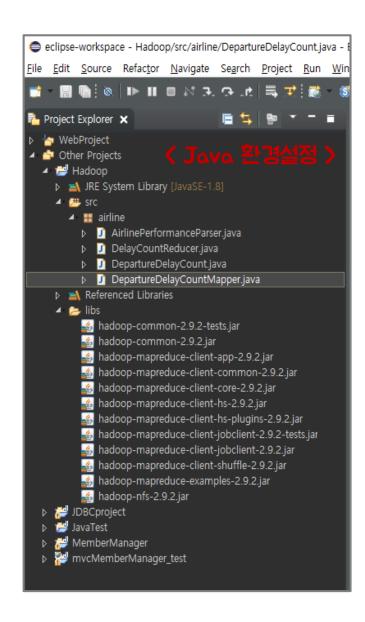
@ wordcount 프로그램 실행

(hadoop jar jar파일경로 클래스 입력파일 출력폴더)
hadoop jar
\$HADOOP_HOME/share/hadoop/mapreduce/hadoop
-mapreduce-examples-2.9.2.jar wordcount
/input/README.txt ~/wordcount-output

@ 작업결과 확인

hdfs dfs -ls ~/wordcount-output
hdfs dfs -cat ~/wordcount-output/part-r-00000

〈 Java Code 를 사용한 HDFS 〉



```
eclipse-workspace - Hadoop/src/airline/DepartureDelayCount.java - Eclipse IDE
                                                                                                                                                                                                                      File Edit Source Refactor Navigate Search Project Run Window Help
                            ID II □ 1/3 7 O 1/2 □ 1/2 1 M · (S) · (Ø) : Æ : #0
                                               AirlinePerformanceP.
      Tomcat v8.5 Server at..
                                                                                       DepartureDelayCount..
                                                                                                                                 DelayCountReducer.java

    DepartureDelayCount.... 

    X

                       org.apache.hadoop.conf.Configuration;
                       t org.apache.hadoop.fs.Path;
t org.apache.hadoop.io.IntWritable;
                       org.apache.hadoop.io.Text
                       org.apache.hadoop.mapreduce.Job;
                       org.apache.hadoop.mapreduce.lib.input.FileInputFormat
                       org.apache.hadoop.mapreduce.lib.input.TextInputFormat
                       org.apache.hadoop.mapreduce.lib.output.FileOutputFormat
                      t org.apache.hadoop.mapreduce.lib.output.TextOutputFormat
            public class DepartureDelayCount {
    public static void main(String[] args) throws Exception {
                      Configuration conf = new Configuration();
if (args.length !=2) {
                                 em. err.println("Usage: DepartureDelayCount <input> <output>");
                     , job job = Job. getinstance(conf, "DepartureDelayCount"); FileInputFormat. addinputPath(job, new Path(args [0])); FileOutputFormat. setOutputPath(job, new Path(args [1]));
                    job.setJarByClass(DepartureDelayCount.class);
job.setMapperClass(DepartureDelayCountMapper.class);
job.setMeducerClass(DelayCountReducer.class);
job.setInputFormatClass(TextPutputFormat.class);
job.setOutputFormatClass(TextOutputFormat.class);
job.setOutputKeyClass(Text.class);
job.setOutputValueClass(IntWritable.class);
job.waitForCompletion(true);
                                                                                                                                  16:50
                                                                                                                                                        <u>**</u>
```

- 1. Hadoop project 생성
- 2. Libs 디렉토리 생성 후 .jar파일 추가

(/home/centos/hadoop-2.9.2/share/hadoop/common 에 있는 3개의 jar파일) (/home/centos/hadoop-2.9.2/share/hadoop/mapreduce 에 있는 9개의 jar파일)

3. Java Build Path -> Libraries -> Add JARs

✓ Java Code > * Java Eclipse에서 작성 *

```
Package airline:
Import java.io.10.Exception;
Import org.apache.hadoop.io.IntWritable;
Import org.apache.hadoop.io.Text;
Import org.apache.hadoop.mapreduce.Reducer;
Public class DelayCountReducer extends
            Reducer(Text, IntWritable, Text, IntWritable) {
 private IntWritable result = new IntWirtable();
 public void reduce(Text key, Iterable(IntWritable)
             values, Context context) throws IOException {
   Int sum = 0:
   for (IntWritable value: values)
     sum+=value.get();
   result set(sum);
   context.write(key,result);
```

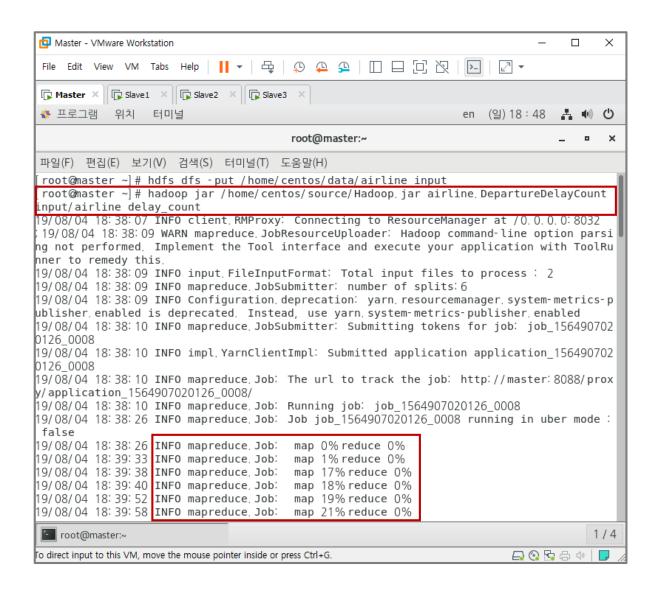
```
package airlines;
Import java.io.10.Exception;
Import org.apache.hadoop.io.IntWritable;
Import org.apache.hadoop.io.LongWritable;
Import org.apache.hadoop.io.Text;
Import org.apache.hadoop.mapreduce.Mapper;
public class DepartureDelayCountMapper extends
         Mapper (Long Writable, Textm Text, Int Writable) {
 private final static IntWritable outputValue =
                                       new IntWritable(1);
 private Text outputKey = new Text();
 public void map(LongWritable key, Text value,
                    Context context) throws IOException{
   AirlinePerformanceParser parser = new
                         AirlinePerformanceParser(value);
   outputKey.set(parser.gerYear() +'.'+parser.getMonth());
   if (parser.getDepartureDelayTime() >0) {
                    context.write(outputkey, outputValue);
```

⟨ Java Code ⟩ * Java Eclipse에서 작성 *

```
package airlines;
import orgapache.hadoop.conf.Configuration ...
public class DepartureDelayCount{
 public static void main(String[] args) throws Exception{
   Configuration conf = new Configuration();
   if (arg.lenth!=2){
     System.err.println('(input) (output)');
    System.exit(2)
   Job job = Job.getInstance(conf, 'DepartureDelayCount');
   FlleInputFormat.addInputPath(job, new Path(args[0]));
   FileOutputFormat.setOutputPath(job, new Path(args[1]));
   job.setJarByClass(DepartureDelayCount.class);
   job.setMapperClass(DepartureDelayCountMapper.class);
   job.setReducerClass(DelayCountReducer.class);
   job.setInputFormatClass(TextInputFormat.class);
   job.setOutputFormatClass(TextOutputFormat.class);
   job.setOutputKeyClass(Text.class);
   job.setOutputValueClass(IntWritable.class);
   job.waitForCompletion(ture);
```

```
package airlines;
import org.apache.hadoop.io.Text;
public class AirlinePerformanceParser{
 private int year;
 private int month;
 public AirlinePerformanceParser(Text text){
   try{
     String[] columns = text.to.String().split(',');
     year = Integer.parseInt(columns[0]);
     month = Integet.parseInt(columns[1]);
     uniqueCarrier = columns(8);
     if (!columns[15].equals('NA')){
       departureDelayTime = Integer.parseInt(columns[15]);
     }else{
       departureDelayAvailable = false;
   }catch (Exception e){
     System.out.println(e.getMessage());
public int getYear() {return year;}
public int getMonth() {return month;}
```

〈 Java Code 를 사용한 HDFS 〉



* master에서 실행 *

@ 작성한 Java Project를 jar파일로 export 이 jar파일을 /home/centos/source에 복사

@ HDFS에 데이터 업로드

(airline 폴더의 데이터 들을 hdfs input 폴더에 업로드) hdfs dfs -mkdir input hdfs dfs -put /home/centos/data/airline input

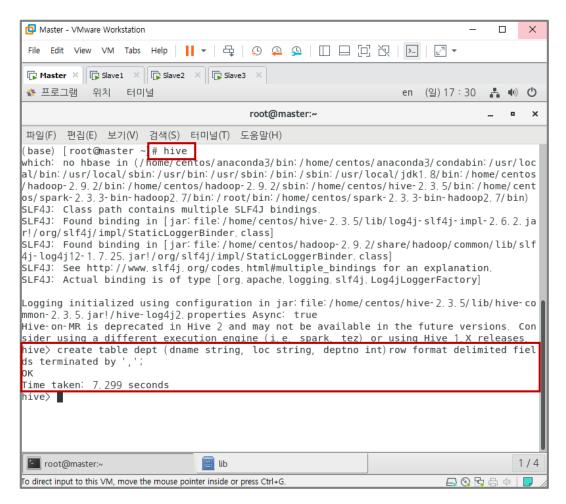
@ Hadoop 환경에서 Hadoop.jar파일 실행
(hadoop jar jar파일경로 클래스 입력데이터위치 출력위치)
hadoop jar /home/centos/source/Hadoop.jar
airline.DepartureDelayCount input/airline
delay_count

```
[root@master ~] # hdfs dfs -cat delay_count/part-r-00000
2006.1 197789
2006.10 248878
2006.11 230224
2006.2 198371
2006.3 235207
2006.4 212412
2006.5 218097
2006.6 263900
2006.7 281457
2006.8 254405
2006.9 209985
2007.1 25
[root@master:~
```

@ 작업결과 확인
hdfs dfs -cat
delay_count/
part-r-00000

2006년 항공 지연 횟수를 윌별로 출력

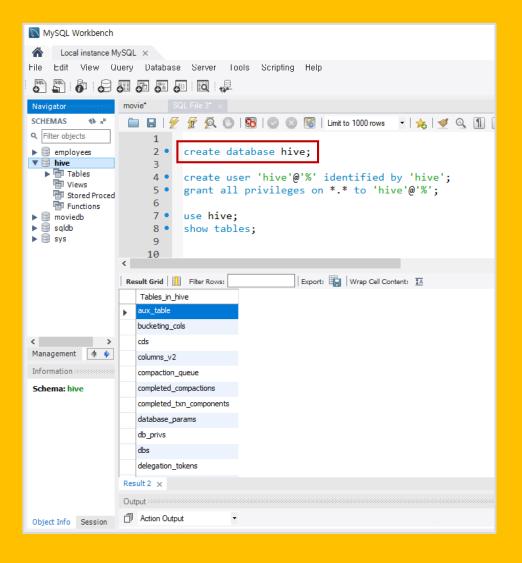
Hive Setup



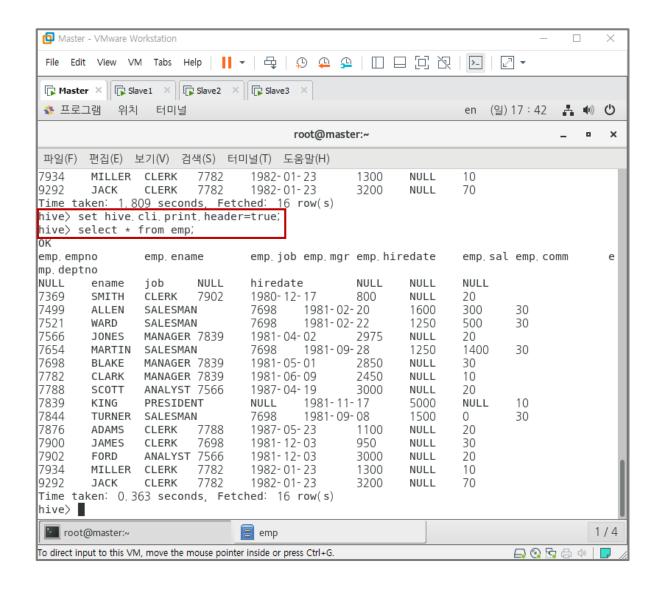
- 윈도우의 MySQL과 연동
- 윈도우의 MySQL을 Java에서 사용할 수 있도록 조정

About Hive

DB, Table의 형태로 HDFS에 저장된 데이터 구조를 정의 SQL과 유사한 HiveQL 쿼리를 사용



〈 Hive 간단 동작 테스트 〉



* master에서 실행 *

@hdfs 디렉토리 생성 & 권한부여

hdfs dfs -mkdir /user/hive/warehouse hdfs dfs -chmod g+x /user/hive hdfs dfs -chmod g+x /user/hive/warehouse

@hive 실행

hive

@테이블 만들기

create table dept (dname string, loc string,

deptno int)

row format delimited ; -> 행 포멧을 지정

fields terminated by ','; -> 필드 구분자는 ,(콤마)로

@데이터 파일불러오기

(inpath 경로의 .csv파일을 읽어서 dept테이블로 읽어오기)

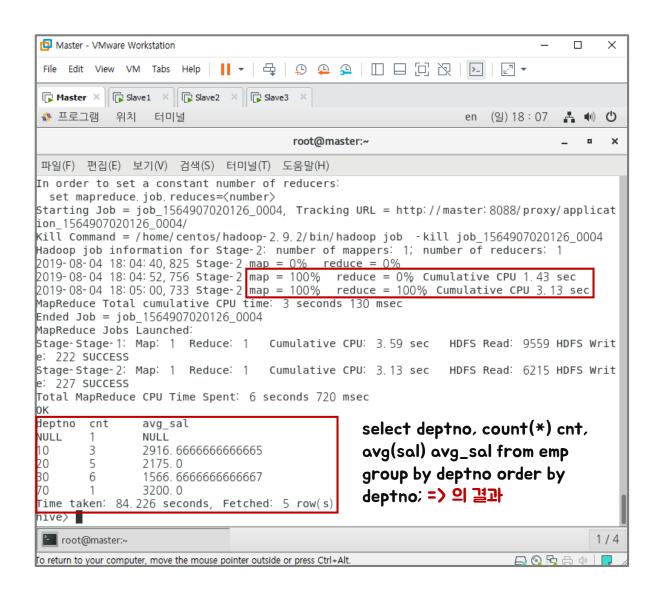
Load data local inpath

'/home/centos/data/dept.csv' overwrite into table dept;

@테이블 확인

select * from dept;

〈 HiveQL을 사용한 HDFS 〉



* master에서 실행 *

@ 테이블 조인

select d.deptno, d.dname, e.ename, e.sal from emp e, dept d where e.deptno=d.deptno;

@ 그룹화

select deptno, count(*) cnt, avg(sal) avg_sal from emp group by deptno order by deptno;

@ 실행결과 저장 (Table에)

create table airport_copy(airport string)

insert overwrite table airport_copy select * from airport_code

select * from airport_copy

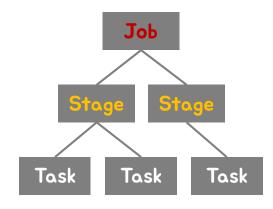
@실행결과 저장 (HDFS에)

insert overwrite directory '/tmp/airport_result'
select * from airport_code;

hdfs dfs -ls /tmp/airport_result/000000_0

About Spark





- 빠른 처리 : 인메모리 기반
- 다양한 언어지원 : Java, Scala, R, Python
- 다양한 컴포넌트 지원 : SQL, Streaming,머신러닝 등
- 다양한 클러스터에서 동작 : Yarn, Mesos, Kubernetes
- 다양한 파일포멧 지원 : Hdfs, Casandra, HBase

인메모리 : 작업의 중간결과를 메모리에 저장하여 반복작업의 처리효율을 높일 수 있다.

' 스파크 컴포넌트 구성 '

Spark Library

- -Spark SQL : SQL을 이용하여 작업을 생성하고 처리
- -Spark Streaming : 실사간 데이터 스트림을 처리
- (스트림 데이터를 작은 사이즈로 쪼개어 RDD처럼 처리)
- -MLib : 스파크 기반의 머신러닝 기능을 제공하는 컴포넌트
- -GraphX : 분산형 그래프 프로세싱이 가능하게 해줌

Spark Core

- -메인 컴포넌트로 작업의 스케줄링, 메모리관리, 장애복구 와 같은 기본적인 기능을 제공
- -RDD, DataSet, DataFrame을 이용한 연산처리 수행

Cluster Manager

- -스파크 작업을 운영하는 클러스터 관리자
- -스파크에서 제공하는 Standalone 관리자 이용가능 (Mesos, Yarn, Kubernetes 등의 관리자도 지원)

About Spark

Spark Job >

• Job : 스파크 애플리케이션으로 제출된 작업

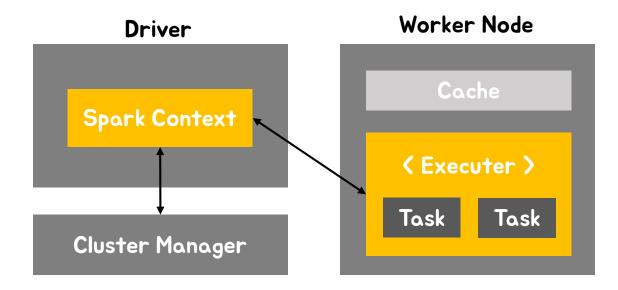
• Stage: Job을 작업단위에 따라 구분한 것

• Task: 익스큐터에서 실행한 실제 작업

Spark Application >

- 스파크 실행 프로그램
- Driver와 Executer로 실행됨
- Cluster Manager가 Spark Application의 리소스를 효율적으로 배분

くSpark 구조 >

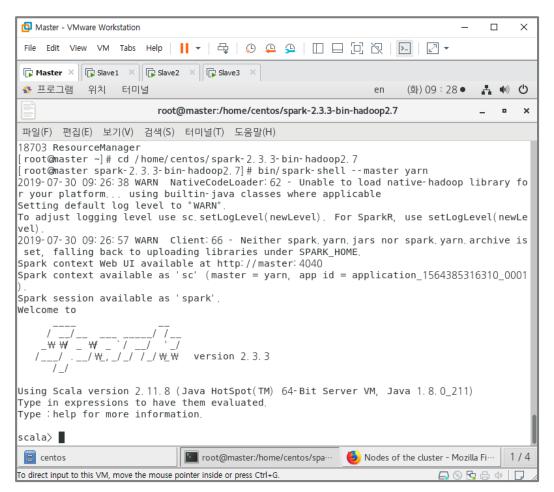


- 1. Driver는 Spark Context 객체를 생성하여 Cluster Manager와 통신하면서 클러스터 자원관리를 지원한다.
- 2. Spark Context는 WorkerNode에서 Executer를 실행하여 실제 작업인 Task를 처리하고, Application의 리사이클을 관리한다.

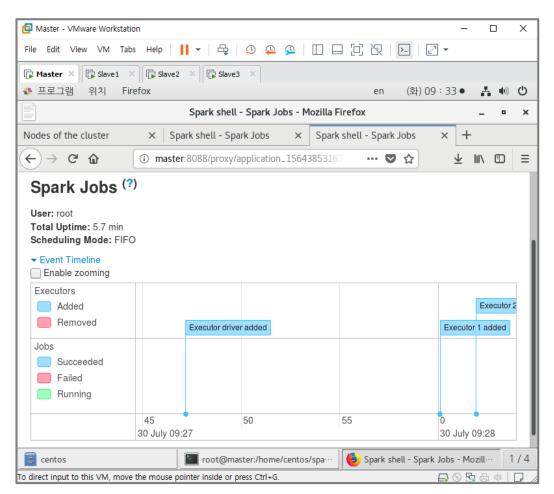
Driver: Spark Application을 실행하는 프로세스

Executer: 실제 작업을 진행하는 프로세서

Spark Setup

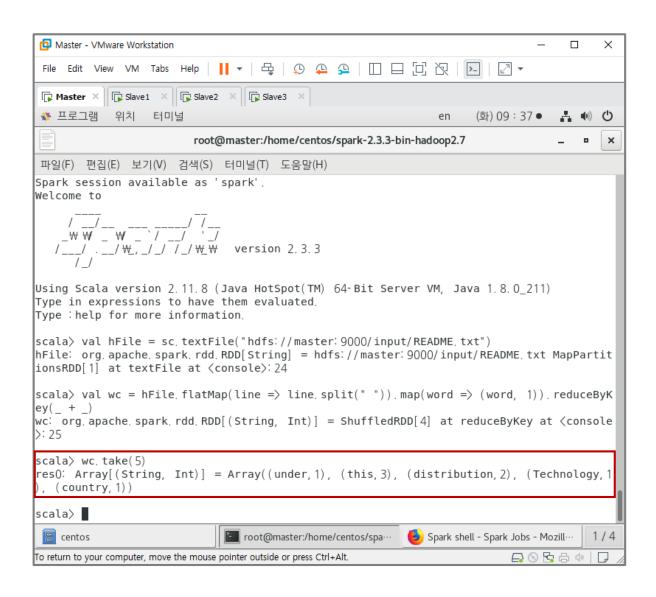


bin/spark-shell --master yarn -> yarn 환경에서 spark실행



http://master:4040 -> spark의 정상작동 확인

〈 Spark 간단 동작 테스트 〉



* master에서 실행 *

@ 테스트 파일을 HDFS에 업로드

hdfs dfs -mkdir /input hdfs dfs -copyFromLocal /home/centos/hadoop-2.9.2/README.txt /input

@ 프로그램 실행하기

Start-dfs.sh Start-yarn.sh Spark-shell --master yarn

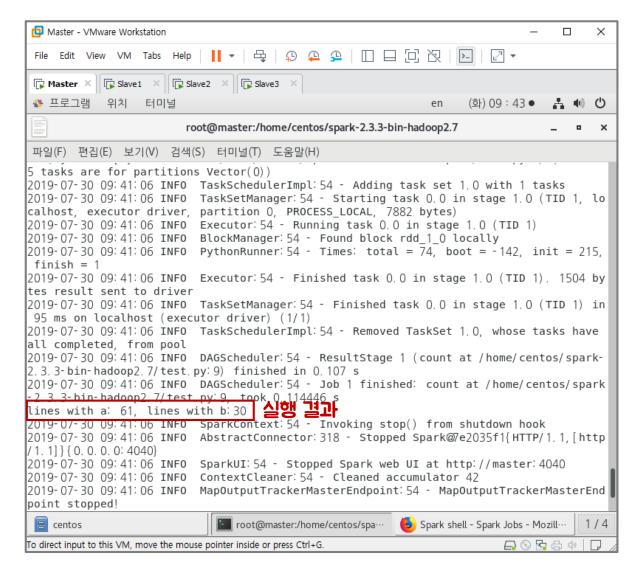
@ 스파크에서 작업

spark> val hFile =
sc.textFile("hdfs://master:9000/input/README.txt
")
spark> val wc = hFile.flatMap(line => line.split("
")).map(word => (word, 1)).reduceByKey(_ + _)
spark> wc.take(5)

@정상출력 확인 -> 다음과 같이 출력되면 정상 실행된 것

Array((String, Int)) = Array((under,1), (this,3),
(distribution,2), (Technology,1), (country,1))

〈 Python을 사용한 Spark 〉



* master에서 실행 * @ python code 작성 \$ vim test.py from pyspark import SparkContext logFile = "/sample/README.md" //hdfs에 올려둔 파일사용 (hdfs://master:9000/sample/README.md) sc = SparkContext("local", "Simple App") logData = sc.textFile(logFile).cache()

```
numA = logData.filter(lambda s: 'a' in s).count()
numB = logData.filter(lambda s: 'b; in s).count()
```

```
print("lines with a: %i, lines with
b:%i" %(numA,numB))
```

@ 작성된 python code 를 실행 \$ bin/spark-submit --master local[4] test.py

〈 감사합니다 〉

Hadoop, Hsive, Spark 프로그램의 설치방법은 저의 GitHub에 올려두었으니 필요하신 분은 참고하시길 바랍니다.

GitHub주소: https://github.com/DabinJeon/HADOOP

